

# 最优化第二次作业

大数据 001

鄧嘯淇

学号：2184114639

2022 年 6 月 11 日

目录	2
----	---

## 目录

1 强凸函数相互等价性	4
1.1 Monotonicity . . . . .	4
1.2 Jensen's Inequality . . . . .	4
1.3 二阶强凸条件 . . . . .	4
2 无穷范数的对偶范数是一范数	5
3 临近算子	5
3.1 二次函数 . . . . .	5
3.2 负自然对数的和 . . . . .	5
4 临近算子基本运算规则	6
4.1 Linear Combination . . . . .	6
4.2 Affine Addition . . . . .	6
4.3 Quadratic Addition . . . . .	6
4.4 Scaling and Translation . . . . .	6
5 优化方法总结	7
6 共轭函数总是凸函数	7
7 Lagrange 对偶问题总是凸优化问题	8
8 等式约束范数极小化	8
9 SVM 的 KKT 条件	9
10 Ridge Regression 的对偶问题	9
11 逻辑回归 loss 为凸函数	10

目录	3
<b>12 Self-Concordant 函数性质与实例</b>	<b>11</b>
12.1 自和谐函数性质 . . . . .	11
12.2 自和谐函数实例 . . . . .	11
12.2.1 第一个 . . . . .	11
12.2.2 第二个 . . . . .	11
12.2.3 第三个 . . . . .	12

# 1 强凸函数相互等价性

## 1.1 Monotonicity

因为  $\nabla g(x)$  为单调函数, 故有  $(\nabla g(y) - \nabla g(x))^T(y - x) \geq 0$

代入  $g(x) = f(x) - \frac{m}{2}x^Tx$ , 有  $(\nabla f(y) - my - \nabla f(x) + mx)^T(y - x) \geq 0$

即  $((\nabla f(y) - \nabla f(x)) - m(y - x))^T(y - x) \geq 0$

即  $(\nabla f(y) - \nabla f(x))^T \geq m\|y - x\|_2^2$

Monotonicity 得证

## 1.2 Jensen's Inequality

由  $g(x)$  为凸函数, 有  $g(\theta x + (1 - \theta)y) \leq \theta g(x) + (1 - \theta)g(y)$ , 代入  $g(x) = f(x) - \frac{m}{2}x^Tx$  有

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) - \frac{m}{2}(\theta x^Tx + (1 - \theta)y^Ty) + \frac{m}{2}(\theta x + (1 - \theta)y)^T(\theta x + (1 - \theta)y)$$

$$\text{即为 } f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) - \frac{m}{2}(1 - \theta)\theta(x^Tx + y^Ty - (xy^T + x^Ty))$$

$$\text{即为 } f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) - \frac{m}{2}(1 - \theta)\theta\|x - y\|_2^2$$

Jensen's Inequality 得证

## 1.3 二阶强凸条件

因为  $g(x)$  为凸函数, 故有  $\nabla^2 g(x) \geq 0$

代入  $g(x) = f(x) - \frac{m}{2}x^Tx$ , 有  $\nabla^2(f(x) - \frac{m}{2}x^Tx) = \nabla^2 f(x) - mI \geq 0$

即  $\nabla^2 f(x) \geq mI$ , 得证

## 2 无穷范数的对偶范数是一范数

对偶范数定义:  $\|u\|_* = \sup_{v \neq 0} \frac{u^T v}{\|v\|} = \sup_{\|v\|=1} u^T v$

再结合霍尔德不等式, 若有  $\frac{1}{p} + \frac{1}{q} = 1$

则  $z^T x \leq \|x\|_p \|z\|_q$

$\|z\|_* = \sup_{x \neq 0} \frac{z^T x}{\|x\|_p} = \|z\|_q$

当  $p = 1$  时, 根据霍尔德不等式,  $q = \infty$

得证

## 3 临近算子

### 3.1 二次函数

$u = \text{prox}^{th}(x)$  最优性条件为

$x - u \in t\partial h(x)$

即  $x - u \in t(Au + b)$

即  $x - u = tAu + tb$

得到  $u = (x - tb)(I + tA)^{-1}$

### 3.2 负自然对数的和

有  $h(x) = -\sum_{n=1}^n \ln x_i$ ,  $u_i = \text{prox}_{th}(x_i)$  最优性条件为

$x - u \in t\partial h(u_i)$

即  $x - u_i + \frac{t}{u_i} = 0$ , 解得  $u_i = \frac{x_i + \sqrt{x_i^2 + 4t}}{2}$

## 4 临近算子基本运算规则

### 4.1 Linear Combination

$$prox_f(x) = \arg \min_z \left\{ \frac{1}{2} \|z - x\|_2^2 + f(z) \right\}$$

$$\text{代入 } f(x) = ag(x) + b, \text{ 有 } prox_{f(x)} = \arg \min_z \left\{ \frac{1}{2} \|z - x\|_2^2 + ag(z) + b \right\}$$

$$\text{即 } f(x) = ag(x) + b, prox_{f(x)} = \arg \min_z \left\{ \frac{1}{2} \|z - x\|_2^2 + ag(z) \right\} = prox_{ag}(x)$$

得证

### 4.2 Affine Addition

$$prox_f(x) = \arg \min_z \left\{ \frac{1}{2} \|z - x\|_2^2 + a^T z + g(z) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2} \|z\|_2^2 - \langle z, x \rangle + a^T z + g(z) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2} \|z\|_2^2 - \langle z, x - a \rangle + g(z) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2} \|z - (x - a)\|_2^2 + g(z) \right\}$$

$$= prox_g(x - a)$$

得证

### 4.3 Quadratic Addition

$$prox(f)(x) = \arg \min_z \left\{ \frac{1}{2} \|z - x\|_2^2 + g(z) + \frac{\rho}{2} \|z - a\|_2^2 \right\}$$

$$= \arg \min_z \left\{ \frac{1+\rho}{2} \|z - x\|_2^2 - \langle z, x + \rho a \rangle + g(z) \right\}$$

$$= \arg \min_z \left\{ \frac{1+\rho}{2} \|z - x\|_2^2 - \frac{1}{1+\rho} \langle z, x + \rho a \rangle + \frac{1}{1+\rho} g(z) \right\}$$

$$= \arg \min_z \left\{ \frac{1+\rho}{2} \|z - (\frac{1}{1+\rho}x + \frac{\rho}{1+\rho}a)\|_2^2 + \frac{1}{1+\rho} g(z) \right\}$$

$$= prox_{\frac{1}{1+\rho}g}(\frac{1}{1+\rho}x + \frac{\rho}{1+\rho}a)$$

得证

### 4.4 Scaling and Translation

如果  $f(\mathbf{x}) = g(a\mathbf{x} + \mathbf{b})$  有  $a \neq 0$  那么

$$\text{prox}_f(\mathbf{x}) = \arg \min_z \left\{ \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + f(\mathbf{z}) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + g(a\mathbf{z} + \mathbf{b}) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2} \|\mathbf{z}\|_2^2 - \langle \mathbf{z}, \mathbf{x} \rangle + g(a\mathbf{z} + \mathbf{b}) \right\}$$

若  $\mathbf{t} = a\mathbf{z} + \mathbf{b}$  那么

$$\mathbf{t} = \arg \min_z \left\{ \frac{1}{2} \left\| \frac{\mathbf{t} - \mathbf{b}}{a} - \mathbf{x} \right\|_2^2 + g(\mathbf{t}) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2a^2} \|\mathbf{t} - (a\mathbf{x} + \mathbf{b})\|_2^2 + g(\mathbf{t}) \right\}$$

$$= \arg \min_z \left\{ \frac{1}{2} \|\mathbf{t} - (a\mathbf{x} + \mathbf{b})\|_2^2 + a^2 g(\mathbf{t}) \right\}$$

$$= \text{prox}_{a^2 g}(a\mathbf{x} + \mathbf{b})$$

$$\text{prox}_f(\mathbf{x}) = \mathbf{z} = \frac{\mathbf{t} - \mathbf{b}}{a} = \frac{1}{a} [\text{prox}_{a^2 g}(a\mathbf{x} + \mathbf{b}) - \mathbf{b}]$$

得证

## 5 优化方法总结

	梯度法	次梯度法	近似点梯度法
步数	$O\left(\frac{1}{k}\right)$	$O\left(k^{\frac{1}{2}}\right)$	$O\left(\frac{1}{k}\right)$
收敛速率	$O\left(\frac{1}{\varepsilon}\right)$	$O\left(\frac{1}{\varepsilon^2}\right)$	$O\left(\frac{1}{\varepsilon}\right)$
若强凸	$O\left(\log\left(\frac{1}{\varepsilon}\right)\right)$	$O\left(\frac{1}{\varepsilon}\right)$	$O\left(\log\left(\frac{1}{\varepsilon}\right)\right)$

## 6 共轭函数总是凸函数

可以看成是一系列关于  $y$  的凸函数取上确界

等价于要证明:  $f^*(\theta t_1 + (1 - \theta)t_2) \leq \theta f^*(t_1) + (1 - \theta)f^*(t_2)$

代入共轭函数的定义, 上述不等式等价于:

$$\max_{x \in \text{dom}(f)} \{(\theta t_1 + (1 - \theta)t_2)x - f(x)\} \leq \theta \max_{x \in \text{dom}(f)} \{t_1 x - f(x)\} + (1 - \theta) \max_{x \in \text{dom}(f)} \{t_2 x - f(x)\}$$

左式等价于:

$$\max_{x \in \text{dom}(f)} \{\theta(t_1 x - f(x)) + (1 - \theta)(t_2 x - f(x))\}$$

假设在  $x_0$  取到最大值, 即:  $\theta(t_1x_0 - f(x_0)) + (1 - \theta)(t_2x_0 - f(x_0))$

又:

$$\begin{aligned}\theta(t_1x_0 - f(x_0)) &\leq \max_{x \in \text{dom}(f)} \{\theta(t_1x_0 - f(x_0))\} \\ (1 - \theta)(t_2x_0 - f(x_0)) &\leq \max_{x \in \text{dom}(f)} \{(1 - \theta)(t_2x_0 - f(x_0))\}\end{aligned}$$

所以原式得证

## 7 Lagrange 对偶问题总是凸优化问题

原问题:

$$\begin{aligned}\min_x & f(x) \\ \text{s.t. } & g_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_j(x) = 0, j = 1, 2, \dots, p\end{aligned}$$

进行一次拉格朗日乘子法, 转换为:

$$\min_{x, \lambda, \nu} L(x, \lambda, \nu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

再求一次对偶问题:

$$\begin{aligned}\max_{\lambda, \nu} \min_x & L(x, \lambda, \nu) \\ \text{s.t. } & \lambda \geq 0\end{aligned}$$

首先约束条件一定是凸函数, 因为它是线性的, 也就是说其实我们现在只要证明:  $\min_x L(x, \lambda, \nu)$  是凸函数即可

$$-\min_x L(x, \lambda, \nu) = -k_1\lambda - k_2\nu - b \text{ if } k_1 = g(x), k_2 = h(x), b = f(x)$$

上面跟  $x$  有关的全部是一个定值。这就是一个线性变化, 或者说仿射变换。然后就用到了我们前面用到的那个重要定理: 仿射集一定是凸集。所以说这是一个凸函数。

## 8 等式约束范数极小化

$$f_0^*(y) = \sup_x (y^T x - \|x\|)$$



根据:  $\|v\|_* = \sup_{\|u\| \leq 1} u^T v$  dual norm of  $\|\cdot\|$

又:  $\|x\| = \sup_x (y^T x), \|y\|_* \leq 1$

如果  $\|y\|_* \leq 1, y^T x \leq \|x\|$ , 显然  $x=0$  时取等号

又:  $\|y\|_* = \sup_x (x^T y) > 1, \|x\| \leq 1$

如果  $\|y\|_* > 1, \exists x, \|x\| \leq 1, \text{ then } x^T y > 1$

$f_0^*(y) \geq y^T(tx) - \|tx\| = t(y^T x - \|x\|) > 0$

$t \rightarrow \infty, f_0^*(y) \rightarrow \infty$

所以:  $f_0^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{otherwise} \end{cases}$  等式约束范数极小化得证

## 9 SVM 的 KKT 条件

原问题

$$\begin{aligned} \min_{\beta, \beta_0, \xi} \quad & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & \xi_i \geq 0, i = 1, 2, 3 \dots n \\ & y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \end{aligned} \tag{1}$$

稳定性条件:  $0 \in \partial_{\beta, \xi} (\frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i + u_i(1 - \xi_i - y_i(x_i^T \beta + \beta_0) + \xi_i))$

互补松弛条件:  $u_i(1 - \xi_i - y_i(x_i^T \beta + \beta_0)) = 0$

原可行性:  $1 - \xi_i - y_i(x_i^T \beta + \beta_0) \leq 0$

对偶可行性:  $u_i \geq 0$

## 10 Ridge Regression 的对偶问题

原岭回归问题, 引入约束条件

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \|x\|_2^2 \quad (2)$$

$$s.t. x = z$$

$$\begin{aligned} \text{有 } g(u) &= \min_x \frac{1}{2} \|Ax - b\|_2^2 + \|z\|_2^2 + u^T(z - x) \\ &= \min_x \frac{1}{2} \|Ax - b\|_2^2 - u^T x + \|z\|_2^2 + u^T z \\ &= \min_x \frac{1}{2} \|Ax - b\|_2^2 - ((A^{-1})^T u)^T (Ax - b) + \|z\|_2^2 + u^T z \\ &= -\|(A^{-1})^T u\|_{2*}^2 - \| -u \|_{2*}^2 - u^T A^{-1} b \\ \text{若有 } \|(A^{-1})^T u\|_* &\leq 1, \| -u \|_* \leq 1 \\ \text{则 } g(u) &= -u^T A^{-1} b \\ \text{对偶问题则为 } \max_u &-u^T A^{-1} b \end{aligned}$$

## 11 逻辑回归 loss 为凸函数

逻辑岭回归

$$\min_{\beta_0, \beta} \sum_{i=1}^n [-y_i(\beta_0 + \beta^T x_i) + \log(1 + e^{\beta_0 + \beta^T x_i})] + \lambda \|\beta\|_2^2$$

其中  $y_i \in \{0, 1\}, x_i \in R^p$

记  $R = -y_i(\beta_0 + \beta^T x_i) + \log(1 + e^{\beta_0 + \beta^T x_i})$

$$\frac{\partial R}{\partial \beta_0} = -\sum_{i=1}^n y_i + \sum_{i=1}^n \frac{e^{\beta_0 + \beta^T x_i}}{1 + e^{\beta_0 + \beta^T x_i}}$$

$$\frac{\partial^2 R}{\partial \beta_0^2} = \sum_{i=1}^n \frac{e^{\beta_0 + \beta^T x_i}}{(1 + e^{\beta_0 + \beta^T x_i})^2}$$

$$\frac{\partial R}{\partial \beta} = -\sum_{i=1}^n x_i y_i + \sum_{i=1}^n \frac{x_i e^{\beta_0 + \beta^T x_i}}{1 + e^{\beta_0 + \beta^T x_i}}$$

$$\frac{\partial^2 R}{\partial \beta^2} = \sum_{i=1}^n \frac{x_i e^{\beta_0 + \beta^T x_i}}{(1 + e^{\beta_0 + \beta^T x_i})^2}$$

$$\frac{\partial^2 R}{\partial \beta_0 \partial \beta} = \frac{\partial^2 R}{\partial \beta_0 \partial \beta_0} = \sum_{i=1}^n \frac{x_i e^{\beta_0 + \beta^T x_i}}{(1 + e^{\beta_0 + \beta^T x_i})^2}$$

设  $t_i = \frac{e^{\beta_0 + \beta^T x_i}}{(1 + e^{\beta_0 + \beta^T x_i})^2} \geq 0$ , 则逻辑岭回归 Hessian 矩阵为

$$H = \begin{pmatrix} \sum_{i=1}^n t_i & \sum_{i=1}^n x_i t_i \\ \sum_{i=1}^n x_i t_i & \sum_{i=1}^n x_i^2 t_i \end{pmatrix}$$

$$y^T H y = \sum_{i=1}^n (x_i + 1)^2 t_i y^T t \geq 0$$

即 Hessian 矩阵半正定, 故凸函数得证。

## 12 Self-Concordant 函数性质与实例

### 12.1 自和谐函数性质

已知为  $f(x)$  自和谐函数, 则做仿射变换  $x = ay + b$ , 令  $f(y) = f(ay + b)$

$$f''(y) = \alpha^2 f''(x), f'''(y) = \alpha^3 f'''(x)$$

$f(x)$  为自和谐函数, 有

$$|f'''(x)| \leq 2(f''(x))^{\frac{3}{2}}$$

两边同时乘  $\alpha^3 (\alpha > 0)$ , 得

$$|\alpha^3 f'''(x)| \leq 2(\alpha^2 f''(x))^{\frac{3}{2}}$$

$$|f'''(x)| \leq |2(f''(y))^{\frac{3}{2}}|$$

自和谐函数仿射变换之后仍为自和谐函数, affine function 成立

### 12.2 自和谐函数实例

#### 12.2.1 第一个

内生函数是关于  $x$  的仿射变换, 为自和谐函数, 外层函数也为自和谐函数, 故整个函数为自和谐函数。

#### 12.2.2 第二个

令  $g(t) = f(X + tV)$  经过分解

$$g(t) = -\log \det(X + tV)$$

$$= -\log \det X - \log \det(I + tX^{-\frac{1}{2}}VX^{-\frac{1}{2}})$$

$$= -\log \det X - \sum_{i=1}^n \log(1 + t\lambda_i), \lambda_i \text{ 为 } X^{-\frac{1}{2}}VX^{-\frac{1}{2}} \text{ 的特征值}$$

$g(t)$  内外层函数均为自和谐函数, 故  $g(t)$  为自和谐函数, 故原函数为自和谐函数。

## 12.2.3 第三个

$$\begin{aligned} f(x) &= -\log(y^2 - x^T x) \\ &= -\log(y^2 - x^T x) - \log x - \log \frac{1}{x} \end{aligned}$$

$$= -\log\left(\frac{y^2}{x}\right) - \log x$$

$$\text{令 } g(x) = \frac{y^2}{x} - x$$

$$g'(x) = -1 - \frac{y^2}{x^2}$$

$$g''(x) = \frac{2y^2}{x^3}$$

$$g'''(x) = -\frac{6y^2}{x^4}$$

$$\text{有 } |g'''(x)| \leq 3 \frac{g''(x)}{x}$$

由此  $f(x)$  为自和谐函数