

最优化理论与算法

1 第一次作业

1.1 证明保凸运算

1. 凸集的交集仍为凸集

证明. 原命题等价于证明: n 个 ($n \geq 0, n \in \mathbb{N}_+$) 凸集的交集仍然是凸集。

1. 当 $n = 1$ 时: \cap 运算是二元运算符, 不考虑这种情况。

2. 当 $n = 2$ 时: 不妨设 A, B 为两个凸集。

当 $A \cap B = \emptyset$ 时, 由凸集的定义, \emptyset 也是一个凸集。

当 $A \cap B \neq \emptyset$ 时, 设 $x_1, x_2 \in A \cap B$, 则 x_1, x_2 也满足 $x_1 \in A$ 且 $x_1 \in B$, $x_2 \in A$ 且 $x_2 \in B$ 。因为 A, B 均为凸集, 由凸集定义:

$$\theta x_1 + (1 - \theta)x_2 \in A \text{ 且 } \theta x_1 + (1 - \theta)x_2 \in B$$

故:

$$\theta x_1 + (1 - \theta)x_2 \in A \cap B$$

3. 假设 $n = k$ 时原命题成立。也即存在凸集 $A_1, A_2 \dots A_k$ 使得。

$$\bigcap_i^k A_i \text{ 为凸集}$$

当 $n = k + 1$ 时, $A_1, A_2 \dots A_{k+1}$ 为凸集, 则:

$$\bigcap_i^{k+1} A_i = \bigcap_i^k A_i \cap A_{k+1}$$

由 $n = 2, n = k$ 时原命题成立可知, $\bigcap_i^k A_i$ 为凸集, A_{k+1} 也为凸集, 故 $\bigcap_i^k A_i \cap A_{k+1}$ 也为凸集。故 $n = k + 1$ 时原命题也成立。

由数学归纳法知: 原命题成立。 □

2. C 是凸集, 则 $aC + b$ 是凸集

证明. 根据题意可知:

$$S = aC + b = \{y | y = ax + b, x \in C\}$$

对 $\forall y_1, y_2 \in S, x_1, x_2 \in C$ 及 $\forall t \in [0, 1]$, 根据集合 S 的定义可得:

$$y_1 = ax_1 + b, y_2 = ax_2 + b$$

$$ty_1 + (1-t)y_2 = t(ax_1 + b) + (1-t)(ax_2 + b) = a(tx_1 + (1-t)x_2) + b$$

$\therefore C$ 为凸集, 根据凸集的定义有: $tx_1 + (1-t)x_2 \in C, t \in [0, 1]$

$\therefore ty_1 + (1-t)y_2 \in S, t \in [0, 1]$, 则 S 为凸集。 \square

3. C 是凸集, $f(x) = Ax + b$, 则仿射项 $f(C)$ 是凸集

证明. 对 $\forall x_1, x_2 \in C$, 由于 C 为凸集, 则 $\forall t \in [0, 1]$

$$tx_1 + (1-t)x_2 \in C$$

对凸集 C 进行仿射变换得到 $AC + b$, 记为集合 S , 由仿射变换的定义可知:

$$x_1, x_2 \in C, Ax_1 + b, Ax_2 + b \in S$$

$$\therefore f(tx_1 + (1-t)x_2) = A(tx_1 + (1-t)x_2) + b = t(Ax_1 + b) + (1-t)(Ax_2 + b) \in S$$

所以 S 为凸集, 该命题得以证明。 \square

4. D 是凸集, $f(x) = Ax + b$, 则原项 $f^{-1}(D)$ 是凸集

证明. 由题意知:

$$f(x) = Ax + b$$

将其变换, 对 x 进行求解得:

$$x = A^{-1}(f(x) - b)$$

等价于:

$$x = A^{-1}f(x) - A^{-1}b$$

令 $x = f(y), f(x) = y, A^{-1} = B, -A^{-1}b = c$, 则可将逆变换的式子写作:

$$f(y) = By + c$$

对比 $f(x) = Ax + b$, 可知逆变换可以写作仿射变换的形式, 由 (1) 所证明的仿射变换的保凸运算, 可得逆变换后仍保凸, 所以该命题得以证明。 \square

1.2 证明无穷范数满足三性质: 正定性, 齐次性和次可加性

证明. 1. 正定性:

$\therefore \|x\|_{\infty} = \max_i |x_i|$, 根据绝对值的性质, $|x| \geq 0$,

$\therefore \|x\|_{\infty} \geq 0$, 若取等, 当且仅当 $x = 0$ 时成立。

即无穷范数具有正定性得以证明。

2. 齐次性:

对于任意实数 t , 有

$$\|tx\|_{\infty} = \max_i |tx_i| = |t| \max_i |x_i| = |t| \|x\|_{\infty}$$

即无穷范数具有齐次性得以证明。

3. 次可加性:

$$\|x + y\|_{\infty} = \max_i |x_i + y_i|$$

$$\begin{aligned}\|x\|_\infty &= \max_i |x_i| \\ \|y\|_\infty &= \max_i |y_i| \\ \max_i |x_i + y_i| &\leq \max_i |x_i| + \max_i |y_i|\end{aligned}$$

即:

$$\|x + y\|_\infty \leq \|x\|_\infty + \|y\|_\infty$$

所以无穷范数的次可加性得以证明。 \square

1.3 证明向量范数均是凸函数

证明. 任取 $x, y \in \mathbb{R}^n$ 有:

$$\theta x + (1 - \theta)y \in \mathbb{R}^n, \theta \in [0, 1]$$

因为

$$\begin{aligned}\|\theta x + (1 - \theta)y\| &\leq \|\theta x\| + \|(1 - \theta)y\| \\ &= \theta \|x\| + (1 - \theta) \|y\|\end{aligned}$$

故向量范数均是凸函数。 \square

1.4 log-sum-exp 函数的凸性

log-sum-exp 函数形式如下: $f(x) = \log(\sum_{i=1}^k e^{x_i})$.

证明. 由题意知

$$f(x) = \log \sum_{k=1}^n \exp x_k$$

对其求一阶偏导得:

$$\frac{\partial f(x)}{\partial x_k} = \frac{e^{x_k}}{\sum_{k=1}^n e^{x_k}} \quad (k = 1, 2 \cdots n)$$

对其求二阶偏导得:

$$\text{当 } k \neq m \text{ 时,} \quad \frac{\partial^2 f(x)}{\partial x_k \partial x_m} = -\frac{e^{x_k} e^{x_m}}{(\sum_{k=1}^n e^{x_k})^2} \quad (k, m = 1, 2 \cdots n)$$

$$\text{当 } k = m \text{ 时,} \quad \frac{\partial^2 f(x)}{\partial x_k \partial x_m} = \frac{-e^{x_k} e^{x_m} + e^{x_k} \sum_{k=1}^n e^{x_k}}{(\sum_{k=1}^n e^{x_k})^2} \quad (k, m = 1, 2 \cdots n)$$

下边证明该矩阵是半正定矩阵。根据半正定矩阵的定义: 对任意的向量 x , 如果有 $x^T A x \geq 0$, 则为半正定矩阵。

定义 n 维列向量 $y = [e^{x_1}, e^{x_2} \cdots e^{x_n}]^T$, 则该函数的 Hessian 矩阵为:

$$H(x) = \frac{1}{(y^T 1)^2} ((y^T 1) \text{diag}(y) - yy^T)$$

其中 1 为全 1 向量, 因为系数为正, 所以直接证明后边的矩阵为半正定。

因为

$$x^T ((y^T 1) \text{diag}(y) - yy^T) x = (y^T 1) x^T \text{diag}(y) x - x^T yy^T x = \sum_i y_i \sum_i (x_i^2 y_i) - (\sum_i x_i y_i)^2$$

令 $a_i = x_i \sqrt{y_i}, b_i = \sqrt{y_i}$, 那么由 Cauchy - Schwarz 公式得:

$$(b^T b)(a^T a) - (a^T b)^2 \geq 0$$

所以该函数的 Hessian 矩阵为半正定矩阵, 则该函数为凸函数。 \square

1.5 如果 f 是严格凸的, 那么其解集唯一, 即解集 X_{opt} 只包含一个元素

证明. 假设该函数不只有一个最小值点, 其中 x 和 $y(x \neq y)$ 均为 f 的最小值点
根据强凸函数的等价定义, 取 $\theta \in (0, 1)$, 则:

$$\begin{aligned} f(\theta x + (1 - \theta)y) &\leq \theta f(x) + (1 - \theta)f(y) - \frac{m}{2}\theta(1 - \theta) \|x - y\|^2 \\ &= f(x) - \frac{m}{2}\theta(1 - \theta) \|x - y\|^2 \\ &< f(x) \end{aligned}$$

与 $f(x)$ 为最小值矛盾, 故假设错误, 原命题成立. □

1.6 假设 f 在全空间 \mathbb{R}^n 可微, 如果 x^* 是一个局部极小点, 那么:

$$\nabla f(x^*) = 0$$

证明. 任取 $v \in \mathbb{R}^n$, 将 f 在点 $x = x^*$ 处泰勒展开

$$f(x^* + tv) = f(x^*) + tv^T \nabla f(x^*) + o(t)$$

整理得

$$\frac{f(x^* + tv) - f(x^*)}{t} = v^T \nabla f(x^*) + o(1)$$

根据 x^* 的最优性, 在上式中分别对 t 取点 0 处的左, 右极限可知

$$\lim_{t \rightarrow 0+} \frac{f(x^* + tv) - f(x^*)}{t} = v^T \nabla f(x^*) \geq 0$$

$$\lim_{t \rightarrow 0-} \frac{f(x^* + tv) - f(x^*)}{t} = v^T \nabla f(x^*) \leq 0$$

即对任意的 v 有 $v^T \nabla f(x^*) = 0$, 由 v 的任意性知 $\nabla f(x^*) = 0$. □

2 第二次作业

2.1 完成强凸函数相互间等价性的证明

- f is strongly convex with parameter $m > 0$ if $g(x) = f(x) - \frac{m}{2}x^T x$ is convex
- Jensen's inequality: Jensen's inequality for g is

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) - \frac{m}{2}\theta(1 - \theta) \|x - y\|_2^2$$

- monotonicity: monotonicity of ∇g gives

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq m \|x - y\|_2^2 \quad \forall x, y \in \text{dom} f$$

this is called strong monotonicity (coercivity) of ∇f

- second-order condition: $\nabla^2 f \succeq mI$ for all $x \in \text{dom} f$

证明. 采用循环论证的方法. 首先由强凸性的定义式, 已知:

$$g(x) = f(x) - \frac{m}{2} x^T x$$

为凸函数, 则 $f(x)$ 为强凸函数. 证明 Jensen's inequality、单调性、二阶条件都是强凸函数的相互等价条件.

(1) **Jensen's inequality**

$g(x)$ 为凸函数, $g(x)$ 必定满足凸性. 由凸性性质, 也是凸性的一个充要条件:

$$\exists \theta \in [0, 1], x, y \in \text{dom} g, \text{ 使得 } g(\theta x + (1 - \theta)y) \leq \theta g(x) + (1 - \theta)g(y)$$

带入 $g(x) = f(x) - \frac{m}{2} x^T x$, 可得:

$$\begin{aligned} & f(\theta x + (1 - \theta)y) - \frac{m}{2} (\theta x + (1 - \theta)y)^T (\theta x + (1 - \theta)y) \\ & \leq \theta f(x) - \frac{m}{2} \theta x^T x + (1 - \theta) f(y) - \frac{m}{2} (1 - \theta) y^T y \end{aligned}$$

等价于:

$$\begin{aligned} & f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta) f(y) \\ & + \frac{m}{2} [\|\theta x + (1 - \theta)y\|_2^2 - \theta x^T x - (1 - \theta) y^T y] \end{aligned}$$

等价于:

$$\begin{aligned} & f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta) f(y) \\ & - \theta(1 - \theta) \frac{m}{2} \|x - y\|_2^2 \end{aligned}$$

故 Jensen's inequality 与强凸性定义式互为等价条件.

(2) **单调性 (monotonicity)**

由强凸性定义式可知: $g(x)$ 为凸函数 $\iff \nabla g(x)$ 是一个单调算子, 也即:

$$(\nabla g(y) - \nabla g(x))^T (y - x) \geq 0, \forall x, y \in \text{dom} g$$

\iff

$$(\nabla f(y) - my - \nabla f(x) + mx)^T (y - x) \geq 0, \forall x, y \in \text{dom} f$$

\iff

$$(\nabla f(y) - \nabla f(x))^T (y - x) \geq m \|x - y\|_2^2, \forall x, y \in \text{dom} f$$

故单调性与强凸性定义式互为等价条件.

(3) **二阶条件 (second-order condition)** 由强凸性定义式可知: $g(x)$ 为凸函数 $\iff \nabla^2 g(x)$ 半正定 (判断凸性的二阶条件), 也即:

$$\nabla^2 f(x) \succeq 0, \forall x \in \text{dom} f$$

由 $g(x) = f(x) - \frac{m}{2} x^T x$, 求 $g(x)$ 的 Hessian 矩阵得:

$$\nabla^2 g(x) = \nabla^2 f(x) - mI \succeq 0$$

$\iff \nabla^2 f(x) \succeq mI$, 故强凸性的二阶条件与强凸性定义式互为等价条件.

□

2.2 证明 ℓ_2 范数的对偶范数为 ℓ_2 范数

证明. 由 Cuchy-Schwartz 不等式:

$$u^T v \leq \|u\|_2 \|v\|_2$$

当且仅当 u 和 v 线性相关时, 等号成立, 取 $v = \frac{u}{\|u\|_2}$ 不等式的最大值为 $\|u\|_2$

$$\begin{aligned}\|u\|_* &= \sup\{u^T z \mid \|z\|_2 \leq 1\} \\ &= \|u\|_2\end{aligned}$$

故 ℓ_2 范数的对偶范数是 ℓ_2 范数得证。 □

2.3 完成如下邻近算子的证明

1. 二次函数

$$h(x) = \frac{1}{2}x^T A x + b^T x + c, \quad \text{prox}_{th}(x) = (I + tA)^{-1}(x - tb)$$

2. 负自然对数的和

$$h(x) = -\sum_{i=1}^n \ln x_i, \quad \text{prox}_{th}(x)_i = \frac{x_i + \sqrt{x_i^2 + 4t}}{2}, \quad i = 1, 2, \dots, n$$

证明. 1. 令 $u = \text{prox}_{th}(x)$, 由邻近算子的最优性条件得:

$$x - u \in \partial h(u) = tAu + tb$$

$$x - u = tAu + tb$$

化简, 得:

$$u = (I + tA)^{-1}(x - tb)$$

所以

$$\text{prox}_{th}(x) = (I + tA)^{-1}(x - tb)$$

2. 令 $u_i = \text{prox}_{th}(x)_i, i = 1, 2, \dots, n$, 由邻近算子的最优性条件得:

$$x_i - u_i \in \partial h(u_i) = -\frac{t}{u_i} (u_i > 0)$$

$$x_i - u_i = -\frac{t}{u_i}$$

解得:

$$u_i = \frac{x_i + \sqrt{x_i^2 + 4t}}{2} (u_i = \frac{x_i - \sqrt{x_i^2 + 4t}}{2} < 0 \text{舍去})$$

所以

$$\text{prox}_{th}(x_i) = \frac{x_i + \sqrt{x_i^2 + 4t}}{2}, i = 1, 2, \dots, n$$

□

2.4 近似点算子基本运算规则证明

完成以下近似点算子基本运算规则证明。

2.4.1 Affine Transformation

若 $f(x) = ag(x) + b$, 其中 $a > 0$, 有: $\text{prox}_f(x) = \text{prox}_{ag}(x)$

证明.

$$\begin{aligned}\text{prox}_f(x) &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \|z - x\|_2^2 + ag(z) + b \right\} \\ &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \|z - x\|_2^2 + ag(z) \right\} \\ &= \text{prox}_{ag}(x)\end{aligned}$$

该运算规则得以证明。 □

2.4.2 Affine Addition

若 $f(x) = g(x) + a^T x + b$, 有: $\text{prox}_f(x) = \text{prox}_g(x - a)$

证明.

$$\begin{aligned}\text{prox}_f(x) &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \|z - x\|_2^2 + g(z) + a^T z + b \right\} \\ &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} (\|z\|_2^2 + \|x\|_2^2 - 2\langle z, x \rangle) + g(z) + \langle z, a \rangle + b \right\} \\ &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} (\|z\|_2^2 + \|x\|_2^2 - 2\langle z, x - a \rangle) + g(z) \right\} \\ &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} (\|z\|_2^2 + \|x\|_2^2 - 2\langle z, x - a \rangle) + g(z) + \frac{1}{2} \|a\|_2^2 - \langle x, a \rangle \right\} \\ &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} (\|z\|_2^2 + \|a\|_2^2 + \|x\|_2^2 - 2\langle z, x - a \rangle - 2\langle x, a \rangle) + g(z) \right\} \\ &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \|z - (x - a)\|_2^2 + g(z) \right\} \\ &= \text{prox}_g(x - a)\end{aligned}$$

该运算规则得以证明。 □

2.4.3 Quadratic Addition

若 $f(x) = g(x) + \frac{\rho}{2} \|x - a\|_2^2$, 有: $\text{prox}_f(x) = \text{prox}_{\frac{1}{1+\rho}g}\left(\frac{1}{1+\rho}x + \frac{1}{1+\rho}a\right)$

证明.

$$\begin{aligned}
\text{prox}_f(x) &= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \|z - x\|_2^2 + g(z) + \frac{\rho}{2} \|z - a\|_2^2 \right\} \\
&= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} (\|z\|_2^2 + \|x\|_2^2 - 2\langle z, x \rangle) + g(z) + \frac{\rho}{2} (\|z\|_2^2 + \|a\|_2^2 - 2\langle z, a \rangle) \right\} \\
&= \underset{z}{\operatorname{argmin}} \left\{ \frac{1+\rho}{2} \|z\|_2^2 - \langle z, x + \rho a \rangle + g(z) \right\} \\
&= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \|z\|_2^2 - \frac{1}{1+\rho} \langle z, x + \rho a \rangle + \frac{1}{1+\rho} g(z) \right\} \\
&= \underset{z}{\operatorname{argmin}} \left\{ \frac{1}{2} \left\| z - \left(\frac{1}{1+\rho} x + \frac{\rho}{1+\rho} a \right) \right\|_2^2 + \frac{1}{1+\rho} g(z) \right\} \\
&= \text{prox}_{\frac{1}{1+\rho}g} \left(\frac{1}{1+\rho} x + \frac{\rho}{1+\rho} a \right)
\end{aligned} \tag{1}$$

该运算规则以证明得。

□

2.4.4 Scaling And Translation

若 $f(x) = g(ax + b)$, 其中 $a \neq 0$, 则有: $\text{prox}_f(x) = \frac{1}{a}(\text{prox}_{a^2g}(ax + b) - b)$

证明. 令 $z = \text{prox}_f(x)$, 由此可知:

$$\begin{aligned}
x - z &\in \partial f(z) = \partial g(ax + b) \\
(ax + b) - (az + b) &\in \partial a^2g(ax + b) \\
\therefore az + b &= \text{prox}_{a^2g}(ax + b) \\
z &= \frac{1}{a}(\text{prox}_{a^2g}(ax + b) - b)
\end{aligned}$$

将 $z = \text{prox}_f(x)$ 带入上式, 可得:

$$\text{prox}_f(x) = \frac{1}{a}(\text{prox}_{a^2g}(ax + b) - b)$$

该运算规则以证明得。

□

2.5 对所有已经学过的迭代算法的收敛速度进行整理

| 方法 | 收敛步数复杂度 |
|----------------|---------------------------------|
| 梯度法 (凸可微) | $O(\frac{1}{\varepsilon})$ |
| 梯度法 (强凸可微) | $O(\log \frac{1}{\varepsilon})$ |
| 次梯度法 (凸不可微) | $O(\frac{1}{\varepsilon^2})$ |
| 次梯度法 (强凸不可微) | $O(\frac{1}{\varepsilon})$ |
| 邻近点梯度法 (凸不可微) | $O(\frac{1}{\varepsilon})$ |
| 邻近点梯度法 (强凸不可微) | $O(\log \frac{1}{\varepsilon})$ |

2.6 共轭函数的凸性证明

函数 f 的共轭函数为:

$$f^*(y) = \sup_{x \in \text{dom } f} (y^T x - f(x))$$

证明共轭函数总是为一凸函数。

方法一. 由题意知, 共轭函数的表达式如下:

$$f^*(y) = \sup_{x \in \text{dom } f} (y^T x - f(x))$$

设 $y_1, y_2 \in \text{dom } f^*$, $t \in [0, 1]$, 将 $y = ty_1 + (1-t)y_2$ 带入共轭函数中, 得:

$$\begin{aligned} & f^*(ty_1 + (1-t)y_2) \\ &= \sup_{x \in \text{dom } f} \{(ty_1 + (1-t)y_2)^T x - f(x)\} \\ &= \sup_{x \in \text{dom } f} \{ty_1^T x + (1-t)y_2^T x - (1-t)f(x) - tf(x)\} \\ &= \sup_{x \in \text{dom } f} \{t(y_1^T x - f(x)) + (1-t)(y_2^T x - f(x))\} \\ &\leq t \sup_{x \in \text{dom } f} \{(y_1^T x - f(x))\} + (1-t) \sup_{x \in \text{dom } f} \{(y_2^T x - f(x))\} \\ &= tf^*(y_1) + (1-t)f^*(y_2) \end{aligned}$$

综上可知, 可得到如下的关系式:

$$f^*(ty_1 + (1-t)y_2) \leq tf^*(y_1) + (1-t)f^*(y_2)$$

根据凸函数的性质可以判定共轭函数 $f^*(y)$ 是凸函数, 且与 $f(x)$ 的凹凸无关。□

方法二. 由题意知, 共轭函数的表达式如下:

$$f^*(y) = \sup_{x \in \text{dom } f} (y^T x - f(x))$$

$\because f^*(y)$ 是关于 y 的仿射函数, 且由相关证明可知, 仿射函数是凸函数。对于每个 x , 都有对应的 $(y^T x - f(x))$ 仿射函数。

$\therefore f^*(y)$ 为一系列凸函数的逐点上确界, 由保凸运算可知, $f^*(y)$ 为凸函数。□

2.7 ℓ_2 范数的共轭函数证明

求证 $f_0 = \|x\|_2$ 的共轭函数为:

$$f_0^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{otherwise} \end{cases}$$

证明. 根据共轭函数定义, 有:

$$f_0^*(y) = \sup_{x \in \text{dom } f} y^T x - f_0(x) = \sup_{x \in \text{dom } f} y^T x - \|x\|$$

根据对偶范数的定义, 有:

$$\|y\|_* = \sup \{y^T z \mid \|z\| \leq 1\}$$

(1) 当 $\|y\|_* > 1$ 时, 存在 $\|z\| \leq 1$, 使 $y^T z > 1$, 故有:

$$y^T x - \|x\| = \lambda(y^T z - \|z\|)$$

其中, $y^T z - \|z\| > 0$ 。令 $\lambda \rightarrow \infty$, 则有:

$$f_0^*(y) = \sup_{x \in \text{dom } f} y^T x - \|x\| = \sup \lambda(y^T z - \|z\|) \rightarrow \infty$$

(2) 当 $\|y\|_* \leq 1$ 时, 根据 Cauchy-Schwarz 不等式, 有:

$$y^T x \leq \|y\|_* \|x\| \leq \|x\|$$

故 $y^T x - \|x\| \leq 0$, 即:

$$f_0^*(y) = \sup_{x \in \text{dom } f} y^T x - \|x\| = 0$$

综上, 一般范数 $\|\cdot\|$ 的共轭函数为:

$$f_0^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{otherwise} \end{cases}$$

□

2.8 Lagrange 对偶问题的凸性证明

证明: Lagrange 对偶问题总是为一凸优化问题:

$$\begin{aligned} \max \quad & g(\lambda, \nu) \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

证明. 由于对偶问题需求解 Lagrange 对偶函数的最大值, 故要证明 Lagrange 对偶问题总是为一凸优化问题, 只需证 $g(\lambda, \nu)$ 为凹函数。

原问题的一般形式为:

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & Ax \leq b \\ & Cx = d \end{aligned}$$

则其 Lagrange 对偶函数为:

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \text{dom } f} (f(x) + (A^T \lambda + C^T \nu)^T x - b^T \lambda - d^T \nu) \\ &= \min[L(x_1, \lambda, \nu), L(x_2, \lambda, \nu), \dots, L(x_n, \lambda, \nu)] \end{aligned} \quad (1)$$

$g(\lambda, \nu)$ 为凹函数的具体证明如下:

记 $t = (\lambda, \nu)$, 故 $g(\theta \lambda_1 + (1 - \theta) \lambda_2, \theta \nu_1 + (1 - \theta) \nu_2)$ 可简便记为 $g(\theta t_1 + (1 - \theta) t_2)$

由 (1) 式可知:

$$\begin{aligned} & \begin{cases} g(\lambda_1, \nu_1) = g(t_1) = \min[L(x_1, t_1), L(x_2, t_1), \dots, L(x_n, t_1)] \\ g(\lambda_2, \nu_2) = g(t_2) = \min[L(x_1, t_2), L(x_2, t_2), \dots, L(x_n, t_2)] \end{cases} \\ g(\theta t_1 + (1 - \theta) t_2) &= \min[L(x_1, \theta t_1 + (1 - \theta) t_2), \dots, L(x_n, \theta t_1 + (1 - \theta) t_2)] \\ &\geq \min[\theta L(x_1, t_1) + (1 - \theta) L(x_1, t_2), \dots, \theta L(x_n, t_1) + (1 - \theta) L(x_n, t_2)] \\ &\geq \theta \min[L(x_1, t_1), \dots, L(x_n, t_1)] + (1 - \theta) \min[L(x_1, t_2), \dots, L(x_n, t_2)] \\ &= \theta g(t_1) + (1 - \theta) g(t_2) \\ &\quad \Downarrow \\ g(\theta \lambda_1 + (1 - \theta) \lambda_2, \theta \nu_1 + (1 - \theta) \nu_2) &\geq \theta g(\lambda_1, \nu_1) + (1 - \theta) g(\lambda_2, \nu_2) \end{aligned}$$

即 Lagrange 对偶函数 $g(\lambda, \nu)$ 满足凹函数的定义, 为凹函数。故 Lagrange 对偶问题总为凸优化问题。 □

2.9 写出岭回归的对偶问题

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_2^2$$

证明. 令 $Ax - b = r$, 则原问题等价于

$$\begin{aligned} \min_{x,r} \quad & \frac{1}{2} \|r\|_2^2 + \mu \|x\|_2^2 \\ \text{s.t.} \quad & Ax - b = r \end{aligned}$$

其拉格朗日函数为:

$$\begin{aligned} L(x, r, v) &= \frac{1}{2} \|r\|_2^2 + \mu \|x\|_2^2 - \langle v, Ax - b - r \rangle \\ &= \frac{1}{2} \|r\|_2^2 + v^T r + \mu \|x\|_2^2 - (A^T v)^T x + b^T v \end{aligned}$$

由二次函数最小值的性质可得:

$$\begin{aligned} g(v) &= \inf_{x,r} L(x, r, v) \\ &= -\frac{1}{2} \|v\|_2^2 - \frac{1}{4\mu} \|A^T v\|_2^2 + b^T v \end{aligned}$$

故其对偶问题是:

$$\max_v \quad -\frac{1}{2} \|v\|_2^2 - \frac{1}{4\mu} \|A^T v\|_2^2 + b^T v$$

□

2.10 自和谐函数计算

2.10.1 自和谐性质一的证明

若 f 是自和谐的, $a \geq 0$, 则 af 也是自和谐的。

证明. 若 $f(x)$ 函数是自和谐函数, 则有:

$$|f'''(x)| \leq 2(f''(x))^{\frac{3}{2}}$$

设函数 $g(x) = af(x)$, $a \geq 1$, 将函数 $g(x)$ 对 x 进行二阶、三阶求导得:

$$g''(x) = a^2 f''(x)$$

$$g'''(x) = a^3 f'''(x)$$

综合上述不等式得:

$$|g'''(x)| = |a^3 f'''(x)| = a^3 |f'''(x)| \leq 2a^3 (f''(x))^{\frac{3}{2}} = 2(a^2 f''(x))^{\frac{3}{2}} = 2(g''(x))^{\frac{3}{2}}$$

即为:

$$|g'''(x)| \leq 2(g''(x))^{\frac{3}{2}}$$

由此可知 $g(x) = af(x)$, $a \geq 1$ 为自和谐函数, 该命题得以证明。

□

2.10.2 自和谐性质二的证明

自和谐函数之和仍为自和谐函数。

证明. 若 f_1, f_2 为自和谐函数, 且 $f_1, f_2 : R \rightarrow R$, 则有:

$$\begin{aligned} |f_1'''(x) + f_2'''(x)| &\leq |f_1'''(x)| + |f_2'''(x)| \\ &\leq 2(f_1''(x))^{\frac{3}{2}} + 2(f_2''(x))^{\frac{3}{2}} \\ &\leq 2(f_1''(x) + f_2''(x))^{\frac{3}{2}} \end{aligned}$$

其中, 最后一个不等式用到了以下不等式:

对任意 $u, v \geq 0$, 则:

$$(u^{\frac{3}{2}} + v^{\frac{3}{2}})^{\frac{2}{3}} \leq u + v$$

该命题得以证明。 □

2.10.3 自和谐性质三的证明

仿射复合: preserved under composition with affine function.

证明. 已知 $f : R^n \rightarrow R$ 是自和谐函数, 根据定义有 $\hat{f}(t) = f(x + tv)$ 是自和谐函数, 其中 $x \in \text{dom } f, v \in R^n$ 。

令 $g(x) = f(Ax + b)$, 则有:

$$\hat{g}(t) = g(x + tv) = f(A(x + tv) + b) = f(Ax + b + tAv)$$

其中, 令 $x' = Ax + b, v' = Av$, 易知 $x' \in \text{dom } f, v' \in R^n$, 则有:

$$\hat{g}(t) = f(x' + tv') = \hat{f}(t)$$

$\hat{g}(t)$ 为自和谐函数, 因此 $g(x) = f(Ax + b)$ 为自和谐函数。所以自和谐性是仿射不变的, 命题即可得证。 □

2.10.4 示例一的证明

若函数 $f(x) = -\sum_{i=1}^m \log(b_i - a_i^T x)$ on $\{x | a_i^T x - b_i < 0\}$, 证明该函数是自和谐函数。

证明. 已知 $f(x) = -\log(x)$ 是自和谐的, 由于自和谐函数的仿射不变性, 得 $f(x) = \log(b_i - a_i^T x)$ 也是自和谐的。

又自和谐对加法保持不变, 故

$$f(x) = -\sum_{i=1}^m \log(b_i - a_i^T x)$$

是自和谐函数。 □

2.10.5 示例二的证明

若函数 $f(x) = -\log \det X$ on S_{++}^n , 证明该函数是自和谐函数。

证明. 该函数为高维函数, 我们考虑将函数限制在直线上, 即令 $\tilde{f}(t) = f(X + tV)$, 其中 $X > 0$, $V \in S^n$. 可以将其表示为

$$\begin{aligned}\tilde{f}(t) &= -\log \det(X^{\frac{1}{2}}(I + tX^{-\frac{1}{2}}VX^{-\frac{1}{2}})X^{\frac{1}{2}}) \\ &= -\log \det(X) - \log \det(I + tX^{-\frac{1}{2}}VX^{-\frac{1}{2}}) \\ &= -\log \det(X) - \sum_{i=1}^n \log(1 + t\lambda_i)\end{aligned}$$

其中 λ_i 是 $X^{-\frac{1}{2}}VX^{-\frac{1}{2}}$ 的特征值. 每个 $-\log(1 + t\lambda_i)$ 是 t 的自和谐函数, 所以他们的和是自和谐的, 由此可知 f 是自和谐的. \square

2.10.6 示例三的证明

利用对数复合规则说明以下函数是自和谐的: $f(x, y) = -\log(y^2 - x^T x)$, 定义域为 $\{(x, y) \mid \|x\|_2 < y\}$.

证明.

$$f(x, y) = -\log(y - \frac{x^T x}{y}) - \log y$$

将 f 限制在直线上, 令 $x = \hat{x} + tv$, $y = \hat{y} + tw$, 代入得

$$f(x = \hat{x} + tv, y = \hat{y} + tw) = -\log(\hat{y} + tw - \frac{\hat{x}^T \hat{x}}{\hat{y} + tw} - \frac{2t\hat{x}^T v}{\hat{y} + tw} - \frac{t^2 v^T v}{\hat{y} + tw}) - \log(\hat{y} + tw)$$

1. 当 $w = 0$ 时,

$$\text{原式} = -\log(\hat{y} - \frac{\hat{x}^T \hat{x}}{\hat{y}} - \frac{2t\hat{x}^T v}{\hat{y}} - \frac{t^2 v^T v}{\hat{y}}) - \log \hat{y}$$

是关于 t 的凹的二次函数的负对数与负对数的和, 这两个函数都是自和谐函数, 故该函数为自和谐函数。

2. 当 $w \neq 0$ 时, 令 $t = \frac{y - \hat{y}}{w}$ 代入, 改为关于 y 的函数, 原式可以写成

$$\begin{aligned}& -\log(y - \frac{\hat{x}^T \hat{x}}{y} - \frac{2\frac{y - \hat{y}}{w}\hat{x}^T v}{y} - \frac{(\frac{y - \hat{y}}{w})^2 v^T v}{y}) - \log y \\ &= -\log(-\frac{2\hat{x}^T v}{w} + \frac{2\hat{y}v^T v}{w^2} - \frac{\hat{x}^T \hat{x}}{y} + \frac{2\hat{y}\hat{x}^T v}{wy} - \frac{\hat{y}^2 v^T v}{w^2 y} + y - \frac{yv^T v}{w^2}) - \log y \\ &= -\log(\alpha + \beta y - \frac{\gamma}{y}) - \log y\end{aligned}$$

其中

$$\begin{aligned}\alpha &= -\frac{2\hat{x}^T v}{w} + \frac{2\hat{y}v^T v}{w^2} \\ \beta &= 1 - \frac{v^T v}{w^2} \\ \gamma &= \hat{x}^T \hat{x} - \frac{2\hat{y}\hat{x}^T v}{w} + \frac{\hat{y}^2 v^T v}{w^2}\end{aligned}$$

定义 $g(y) = -\alpha - \beta y + \frac{\gamma}{y}$, 它是凸函数 $\gamma > 0$ 在最后证明, 且满足

$$|g'''(y)| \leq \frac{3g''(y)}{y},$$

其中, $g'''(y) = -\frac{6\gamma}{y^4}$, $g''(y) = \frac{2\gamma}{y^3}$ 故函数为自和谐函数

下面补充证明 $\gamma > 0$:

$$\begin{aligned}\gamma &= \hat{x}^T \hat{x} - \frac{2\hat{y}\hat{x}^T v}{w} + \frac{\hat{y}^2 v^T v}{w^2} \\ &= \hat{x}^2 - \frac{2\hat{y}\hat{x}v}{w} + \frac{\hat{y}^2 v^2}{w^2} \\ &= \frac{\hat{x}^2 w^2 - 2\hat{y}\hat{x}v w + \hat{y}^2 v^2}{w^2} \\ &= \frac{(\hat{x}w - \hat{y}v)^2}{w^2} \geq 0\end{aligned}$$

□

2.11 (选做) 次微分基本运算规则

- 1. scaling: $\partial(\alpha f) = \alpha \partial f$ (for $\alpha > 0$)
- 2. summation: $\partial(f_1 + f_2) = \partial f_1 + \partial f_2$
- 3. affine transformation: if $h(x) = f(Ax + b)$, then

$$\partial h(x) = A^T \partial f(Ax + b)$$

- 4. chain rule: suppose f is convex, and g is differentiable, nondecreasing, and convex. Let $h = g \circ f$, then

$$\partial h(x) = g'(f(x)) \partial f(x)$$

证明. • 1. 取 $g_1 \in \partial f$

$$f(y) \geq f(x) + g_1^T(y - x)$$

$$\alpha f(y) \geq \alpha f(x) + \alpha g_1^T(y - x)$$

则 $\alpha g_1 \in \partial(\alpha f)$

取 $g_2 \in \partial(\alpha f)$

$$\alpha f(y) \geq \alpha f(x) + g_2^T(y - x)$$

$$f(y) \geq f(x) + \frac{1}{\alpha} g_2^T(y - x)$$

则 $\frac{1}{\alpha} g_2 \in \partial f$

所以 $\partial(\alpha f) = \alpha \partial f$ (for $\alpha > 0$)

- 2. 取 $g_1 \in \partial f_1 + \partial f_2$

$$\partial f_1(y) + \partial f_2(y) \geq \partial f_1(x) + \partial f_2(x) + g_1^T(y - x)$$

$$\partial(f_1 + f_2)(y) \geq \partial(f_1 + f_2)(x) + g_1^T(y - x)$$

则 $g_1 \in \partial(f_1 + f_2)$

取 $g_2 \in \partial(f_1 + f_2)$

$$\partial(f_1 + f_2)(y) \geq \partial(f_1 + f_2)(x) + g_2^T(y - x)$$

$$\partial f_1(y) + \partial f_2(y) \geq \partial f_1(x) + \partial f_2(x) + g_2^T(y - x)$$

则 $g_2 \in \partial f_1 + \partial f_2$

所以 $\partial(f_1 + f_2) = \partial f_1 + \partial f_2$

- 3. 取 $g_1 \in \partial f(Ax + b)$

$$\begin{aligned} f(Ay + b) &\geq f(Ax + b) + g_1^T[(Ay + b) - (Ax + b)] \\ &= f(Ax + b) + g_1^T A(y - x) \end{aligned}$$

$$h(y) \geq h(x) + (A^T g_1)^T(y - x)$$

则 $A^T g_1 \in \partial h(x)$

取 $g_2 \in \partial h(x)$

$$h(y) \geq h(x) + g_2^T(y - x)$$

$$f(Ay + b) \geq f(Ax + b) + g_2^T(y - x)$$

$$f(Ay + b) \geq f(Ax + b) + g_2^T A^{-1}[(Ay + b) - (Ax + b)] \text{ (仿射变换是可逆的)}$$

$$f(Ay + b) \geq f(Ax + b) + ((A^{-1})^T g_2)^T[(Ay + b) - (Ax + b)]$$

则 $(A^{-1})^T g_2 = (A^T)^{-1} g_2 \in \partial f(Ax + b)$

所以 $\partial h(x) = A^T \partial f(Ax + b)$

- 4. 设 $z \in \partial g(f(x)), g_1 \in \partial f(x)$

$$\begin{aligned} h(x) &= g(f(x)) \geq g(f(x_0) + g_1^T(x - x_0)) \\ &\geq g(f(x_0)) + z^T g_1^T(x - x_0) \\ &= h(x_0) + (g_1 z)^T(x - x_0) \end{aligned}$$

则 $g_1 z \in \partial h(x)$

所以 $\partial h(x) = g'(f(x)) \partial f(x)$

□

2.12 (选做)

- 证明 ℓ_∞ 范数的对偶范数是 ℓ_1 范数。
- 证明任意 ℓ_p 范数 $\ell_p : \|x\|_p = \sqrt[p]{\sum_1^n |x_i|^p}$ 满足范数三条性质 (正定性, 齐次性, 三角性)。
- 进一步证明任意 ℓ_p 范数的对偶范数为 ℓ_q 范数, 当且仅当 $\frac{1}{p} + \frac{1}{q} = 1, p \geq 1, q \geq 1$ 时成立。

证明. 1 对 $\forall u, v \in \mathbb{R}^n$

$$\|v\|_1 = \sum_{i=1}^n |v_i|$$

$$\|u\|_* = \sup_{v \neq 0} \frac{u^T v}{\|v\|} = \sup_{\|v\|_\infty \leq 1} u^T v$$

且对 $\forall v \in \mathbb{R}^n$ 且 $\|v\|_1 \leq 1$ 有

$$u^T v = \sum_{i=1}^n u_i v_i$$

$$\leq \sum_{i=1}^n |u_i| |v_i|$$

取

$$k = \{i | \max_i |u_i|\}$$

则

$$u^T v \leq \sum_{i=1}^n |u_i| |v_i|$$

$$= \sum_{i=1}^n |u_k| |v_i| - \sum_{i=1}^n (|u_k| - |u_i|) |v_i|$$

$$= |u_k| \sum_{i=1}^n |v_i| - \sum_{i=1}^n (|u_k| - |u_i|) |v_i|$$

$$\leq |u_k| - \sum_{i=1}^n (|u_k| - |u_i|) |v_i|$$

$$\leq |u_k|$$

即

$$u^T v \leq \|u\|_\infty$$

且当 v 满足

$$v_k = \text{sign}(u_k)$$

$$v_i = 0 \ (i \neq k)$$

时取等, 所以 $\|u\|_* = \sup_{\|v\| \leq 1} u^T v = \|u\|_\infty$

即 l_1 范数的对偶范数为 l_∞ 范数

2 1. 正定性

$\|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p} \geq 0$, 当且仅当 $\mathbf{x} = 0$ 时取等号。

对于任意的 $\forall i = 1, 2, \dots, n$, $|x_i| \geq 0$, 所以有 $\sum_{i=1}^n |x_i|^p \geq 0$, 所以有:

$$\|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p} \geq 0$$

2. 齐次性

即证 $\|c\mathbf{x}\|_p = |c|\|\mathbf{x}\|_p$ 。因为

$$\|c\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^n |cx_i|^p} = \sqrt[p]{\sum_{i=1}^n |c|^p |x_i|^p} = |c| \sqrt[p]{\sum_{i=1}^n |x_i|^p}$$

故齐次性得证。

3. 三角性

即证 $\|\mathbf{x}\|_p + \|\mathbf{y}\|_p \geq \|\mathbf{x} + \mathbf{y}\|_p$ 因为:

$$\|\mathbf{x} + \mathbf{y}\|_p = \sqrt[p]{\sum_{i=1}^n |x_i + y_i|^p} \leq \sqrt[p]{\sum_{i=1}^n (|x_i|^p + |y_i|^p)} \leq \sqrt[p]{\sum_{i=1}^n |x_i|^p} + \sqrt[p]{\sum_{i=1}^n |y_i|^p}$$

三角性得证。

3 利用 *Hölder's inequality* 进行证明, 即:

$$\sum_{k=1}^n |x_k y_k| \leq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |y_k|^q \right)^{\frac{1}{q}} \text{ for all } (x_1, \dots, x_n), (y_1, \dots, y_n) \in \mathbb{R}^n \text{ or } \mathbb{C}^n.$$

$$\text{对 } \forall z, x \in \mathbb{R}^n, \text{ 且 } \|z\|_p = \left(\sum_{i=1}^n |z_i|^p \right)^{\frac{1}{p}} \leq 1$$

$$z^T x = \sum_{i=1}^n z_i x_i \leq \sum_{i=1}^n |z_i x_i| = \sum_{i=1}^n |z_i| |x_i|$$

对 $\forall a, b > 0, \forall \theta \in [0, 1]$ 有

$$\theta a + (1 - \theta)b \geq a^\theta b^{(1-\theta)}$$

当且仅当 $a = b$ 时, 对 $\forall \theta \in [0, 1]$ 成立

令 $\theta = \frac{1}{p}, 1 - \theta = \frac{1}{q}$, 则

$$\frac{a}{p} + \frac{b}{q} \geq a^{\frac{1}{p}} b^{\frac{1}{q}}$$

则对 $\forall i = 1, 2, \dots, n$ 有

$$\frac{1}{p} \frac{|z_i|^p}{\sum_{i=1}^n |z_i|^p} + \frac{1}{q} \frac{|x_i|^q}{\sum_{i=1}^n |x_i|^q} \geq \frac{|z_i|}{\left(\sum_{i=1}^n |z_i|^p \right)^{\frac{1}{p}}} \frac{|x_i|}{\left(\sum_{i=1}^n |x_i|^q \right)^{\frac{1}{q}}}$$

不等式两边 n 项求和得

$$\frac{1}{p} + \frac{1}{q} = 1 \geq \frac{\sum_{i=1}^n |z_i| |x_i|}{\left(\sum_{i=1}^n |z_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^n |x_i|^q \right)^{\frac{1}{q}}}$$

即

$$\sum_{i=1}^n |z_i| |x_i| \leq \|z\|_p \|x\|_q \leq \|x\|_q$$

且令

$$|z_i|^p = \frac{|x_i|^q}{\sum_{i=1}^n |x_i|^q}, \quad i = 1, 2, \dots, n$$

$$\text{sign}(z_i) = \text{sign}(x_i), \quad i = 1, 2, \dots, n$$

可取等

$$\text{所以 } \|x\|_* = \sup_{\|z\|_p \leq 1} z^T x = \|x\|_q$$

即 l_p 范数的对偶范数是 l_q 范数, 其中 p, q 满足 $\frac{1}{p} + \frac{1}{q} = 1$ 且 $p, q \geq 1$

□